

Génération de données pour la détection de changements sémantique à très haute résolution spatiale

Journée de la Recherche Univ. Eiffel-IGN-ENSG

Yanis Benidir

Encadrement : Clément Mallet - Nicolas Gonthier

11 mars 2025




- 1 La détection de changements, un challenge complexe
- 2 Génération de données synthétiques
- 3 Transfert d'apprentissage et expérimentations

- 1 La détection de changements, un challenge complexe
- 2 Génération de données synthétiques
- 3 Transfert d'apprentissage et expérimentations

Quelles données ? Quels changements ?

Données

- Très Haute Résolution spatiale
- Images aériennes (0.05 ~ 0.5m)
- RGB



(a) T_0



(b) T_1



(c) Label T_0



(d) Label T_1



(e) Changement

Figure: Exemple issu du jeu de changements HiUCD


Quelles données ? Quels changements ?

Données

- Très Haute Résolution spatiale
- Images aériennes ($0.05 \sim 0.5m$)
- RGB

Changements

- Pérennes
- Bi-dates
- Multi-classes ("sémantique")



(a) T_0



(b) T_1



(c) Label T_0



(d) Label T_1



(e) Changement

Figure: Exemple issu du jeu de changements HiUCD

Deep Learning pour la détection de changements




Figure: Apprentissage supervisé pour la détection de changements sémantique

Une tâche complexe

**Jeux de données restreints,
non exhaustifs**



(a) T_0




(b) T_1

Figure: Différences radiométriques



(a) T_0



(b) T_1

Figure: Changement temporaire



(a) T_0



(b) T_1

Figure: Dévers

Comment pallier le manque de données pour l'apprentissage supervisé

- Compléter les datasets pour obtenir une base d'apprentissage correcte

Adapter l'apprentissage des modèles aux données disparates

- Le transfert d'apprentissage comme clé
- Explorer et évaluer différentes méthodes de transfert
- Mettre en place une architecture simple et efficace

Améliorer l'apprentissage avec des données synthétiques




Figure: Schéma global de notre processus

Objectifs

- Un jeu de données artificiel et modulable de changement : FSC-180k
- Une étude du transfert d'apprentissage pour la détection de changement

- 1 La détection de changements, un challenge complexe
- 2 Génération de données synthétiques
- 3 Transfert d'apprentissage et expérimentations

Stable Diffusion, modèle génératif *text-to-image*



Un modèle "geographically-informed" ...

- Prompts textuels en entrée
- Noms des classes sémantiques
- Informations sur le lieu (via OSM)
- Informations sur le moment

"top view of *road and grass and brushwood* next to *a road in the locality of Vendresse, Grand Est*, in *the morning, during summer*, high resolution, highly detailed"




Figure: Carte sémantique RGB

... et "*semantically & spatially-guided*"

- Entrée du ControlNet
- Carte sémantique RGB (légende classes-couleurs)
- "Vérité terrain" de l'image générée

Pipeline de génération : HySCDG




Figure: HySCDG, notre pipeline de génération - Processus "Select, mask, change, inpaint"

BDUni : base de données topographique IGN

- 1 La détection de changements, un challenge complexe
- 2 Génération de données synthétiques
- 3 Transfert d'apprentissage et expérimentations**

Entraînement "séquentiel"

- Phase 1 : entraînement sur données synthétiques
- Phase 2 : *Fine-tuning* sur données cibles (réelles)

Entraînement "séquentiel"

- Phase 1 : entraînement sur données synthétiques
- Phase 2 : *Fine-tuning* sur données cibles (réelles)

Entraînement "mixé"

- Entraînement sur mélange "synthétique + réel"

Entraînement "séquentiel"

- Phase 1 : entraînement sur données synthétiques
- Phase 2 : *Fine-tuning* sur données cibles (réelles)

Entraînement "mixé"

- Entraînement sur mélange "synthétique + réel"

Low data regime

- Quantité restreinte de données réelles annotées (1%, 10%, 30%)
- Entraînement "séquentiel" avec fine-tuning sur ce petit lot de données seulement

Expérimentations

Entraînement "séquentiel"

- Phase 1 : entraînement sur données synthétiques
- Phase 2 : *Fine-tuning* sur données cibles (réelles)

Entraînement "mixé"

- Entraînement sur mélange "synthétique + réel"

Low data regime

- Quantité restreinte de données réelles annotées (1%, 10%, 30%)
- Entraînement "séquentiel" avec fine-tuning sur ce petit lot de données seulement

Zero-shot

- Application directe du modèle pré-entraîné aux données cibles

Entraînement "séquentiel"

- Amélioration des performances dans tous les cas grâce à FSC-180k





Figure: Résultats mode "séquentiel"

Low data regime

- Pré-entraînement efficace pour compléter un jeu de données restreint



Exemples




Figure: Exemples de prédictions sur SECOND

Exemples




Figure: Exemples issus de FSC-180k

Points clés

- Très Haute Résolution $\Rightarrow$ Nombreux challenges
- Jeux de données **très limités** pour du *Deep Learning*
- Modèles de diffusion $\Rightarrow$ avancée majeure pour la **génération synthétique**
- HySCDG $\Rightarrow$ génération de données **hybrides et réalistes**
- Un **transfert d'apprentissage** très efficace avec **FSC-180k**

Pipeline de génération : HySCDG

"top view of road and grass and brushwood next to a road in the locality of Vendresse, Grand Est, in the morning, during summer, high resolution, highly detailed"




Figure: Carte sémantique RGB



Figure: Image générée

Stable Diffusion, modèle génératif *text-to-image*




Figure: Fonctionnement général de Stable Diffusion

Learning on an imbalanced dataset

- Changes prevalence : 3%
- ROC curve and optimal threshold
- Better separation between positives and negatives after long training
- Semantic predictions : bias due to the shared autoencoder

Jeux de données de changements

Nom	Classes	Résolution	Pixels ($\times 10^6$)
Jeux de changements bi-dates			
HRSCD [Daudt et al., 2019]	5	0.5 m 	29100

Table: Exemples de jeux de données de changement

 : Images satellite
 : Images aériennes

France
Taille

Annotations grossières

Jeux de données de changements

Nom	Classes	Résolution	Pixels ($\times 10^6$)
Jeux de changements bi-dates			
HRSCD [Daudt et al., 2019]	5	0.5 m 	29100
LevirCD [Chen and Shi, 2020]	1	0.5 m 	668

Table: Exemples de jeux de données de changement

 : Images satellite
 : Images aériennes

Renommée : "étalon"

Bâtiments uniquement
Trop "facile"

Jeux de données de changements

Nom	Classes	Résolution	Pixels ($\times 10^6$)
Jeux de changements bi-dates			
HRSCD [Daudt et al., 2019]	5	0.5 m 	29100
LevirCD [Chen and Shi, 2020]	1	0.5 m 	668
HiUCD-mini [Tian et al., 2020]	9	0.1 m 	7

Table: Exemples de jeux de données de changement



: Images satellite
: Images aériennes

Paysages "européens"
Très haute résolution

Très petit
Plutôt "difficile"
Annotations manquantes

Jeux de données de changements

Nom	Classes	Résolution	Pixels ($\times 10^6$)
Jeux de changements bi-dates			
HRSCD [Daudt et al., 2019]	5	0.5 m 	29100
LevirCD [Chen and Shi, 2020]	1	0.5 m 	668
HiUCD-mini [Tian et al., 2020]	9	0.1 m 	7
SECOND [Yang et al., 2020]	6	variable 	1200

Table: Exemples de jeux de données de changement

 : Images satellite
 : Images aériennes

"Étalon"	Annotations grossières Images de qualité moyenne
----------	---

Jeux de données de changements

Nom	Classes	Résolution	Pixels ($\times 10^6$)
Jeux de changements bi-dates			
HRSCD [Daudt et al., 2019]	5	0.5 m 	29100
LevirCD [Chen and Shi, 2020]	1	0.5 m 	668
HiUCD-mini [Tian et al., 2020]	9	0.1 m 	7
SECOND [Yang et al., 2020]	6	variable 	1200
Occupation du sol uniquement (pas de changement)			
Flair [Garioud et al., 2023]	19	0.2m 	20300

Table: Exemples de jeux de données de changement

 : Images satellite
 : Images aériennes

Tuning the synthetic dataset

Problematic	Tested solution
Ambient changes	Image augmentation
Classes inbalance	Adapting proportions of classes
Inpainting detection	"Fake" inpaintings
Specific landscapes	Oversampling of categories of images
Specific classes	Specific change trajectories selection

Table: Experiments to customize the synthetic dataset

Fully artificial

- SyntheWorld [Song et al., 2023] - Blender + ChatGPT + StableDiffusion
- SMARS [Fuentes Reyes et al., 2023] - Blender



Figure: Samples from the SyntheWorld dataset

References I



Chen, H. and Shi, Z. (2020).

A spatial-temporal attention-based method and a new dataset for remote sensing image change detection.

Remote Sensing, 12(10).



Daudt, R., Le Saux, B., Boulch, A., and Gousseau, Y. (2019).

Multitask learning for large-scale semantic change detection.

Computer Vision and Image Understanding, 187:102783.



Fuentes Reyes, M., Xie, Y., Yuan, X., d'Angelo, P., Kurz, F., Cerra, D., and Tian, J. (2023).

A 2d/3d multimodal data simulation approach with applications on urban semantic segmentation, building extraction and change detection.

ISPRS Journal of Photogrammetry and Remote Sensing, 205:74–97.

References II



Garioud, A., Gonthier, N., Landrieu, L., Wit, A. D., Valette, M., Poupée, M., Giordano, S., and Wattralos, B. (2023).

FLAIR : a country-scale land cover semantic segmentation dataset from multi-source optical imagery.

In *Thirty-seventh Conference on Neural Information Processing Systems Datasets and Benchmarks Track*.



Song, J., Chen, H., and Yokoya, N. (2023).

Syntheworld: A large-scale synthetic dataset for land cover mapping and building change detection.



Tian, S., Zhong, Y., Ma, A., and Zheng, Z. (2020).

Hi-ucd: A large-scale dataset for urban semantic change detection in remote sensing imagery.



Yang, K., Xia, G.-S., Liu, Z., Du, B., Yang, W., Pelillo, M., and Zhang, L. (2020).

Semantic change detection with asymmetric siamese networks.